

DeepSeek V4 Flash 推理性能测试报告

模型: deepseek-v4-flash 端点: http://10.10.12.11:8888
测试时间: 2026-08-05 04:35:02
矩阵: 并发 1/3/5/8/10 × 输入输出 50/500/1024/2048 tokens

TTFT p90 (ms)

IO len	C=1	C=3	C=5	C=8	C=10
50	175.5	222.7	242.5	288.3	275.4
500	357.0	656.6	6553.2	943.9	1242.4
1024	419.8	695.2	649.2	910.2	1292.8
2048	4090.4	6066.7	564.4	762.7	1144.3

平均 TPS (tok/s)

IO len	C=1	C=3	C=5	C=8	C=10
50	70.32	35.06	29.65	22.52	26.81
500	54.81	35.70	25.78	22.70	19.85
1024	55.96	35.63	28.79	26.96	22.65
2048	53.82	40.29	28.99	25.32	22.47

聚合吞吐 (tok/s)

IO len	C=1	C=3	C=5	C=8	C=10
50	61.93	90.10	126.28	150.57	221.30
500	53.20	101.01	97.31	165.67	186.48
1024	54.11	95.23	113.89	117.07	148.45
2048	47.28	71.32	98.31	136.04	156.95

端到端平均延迟 (ms)

IO len	C=1	C=3	C=5	C=8	C=10
50	1431.4	2523.4	3197.0	4358.7	3621.6
500	12192.8	19074.9	29534.4	29674.3	33700.2
1024	17512.1	23873.8	26718.7	23730.5	35639.8
2048	17174.3	29690.6	26382.8	30568.8	34135.1

详细数据

C	输入	输出	成功	失败	TTFT mean	TTFT p90	TPS mean	聚合吞吐	E2E mean
1	50	50	3	0	147.5	175.5	70.32	61.93	1431.4
1	500	500	3	0	337.9	357.0	54.81	53.20	12192.8
1	1024	1024	3	0	371.9	419.8	55.96	54.11	17512.1
1	2048	2048	3	0	1900.9	4090.4	53.82	47.28	17174.3
3	50	50	3	0	221.8	222.7	35.06	90.10	2523.4
3	500	500	3	0	483.4	656.6	35.70	101.01	19074.9
3	1024	1024	3	0	559.4	695.2	35.63	95.23	23873.8
3	2048	2048	3	0	6066.1	6066.7	40.29	71.32	29690.6
5	50	50	5	0	241.4	242.5	29.65	126.28	3197.0
5	500	500	5	0	5303.3	6553.2	25.78	97.31	29534.4
5	1024	1024	5	0	647.8	649.2	28.79	113.89	26718.7
5	2048	2048	5	0	562.8	564.4	28.99	98.31	26382.8
8	50	50	8	0	285.7	288.3	22.52	150.57	4358.7
8	500	500	8	0	941.5	943.9	22.70	165.67	29674.3
8	1024	1024	8	0	908.4	910.2	26.96	117.07	23730.5
8	2048	2048	8	0	760.9	762.7	25.32	136.04	30568.8
10	50	50	10	0	272.3	275.4	26.81	221.30	3621.6
10	500	500	10	0	1240.3	1242.4	19.85	186.48	33700.2
10	1024	1024	10	0	1190.1	1292.8	22.65	148.45	35639.8
10	2048	2048	10	0	1056.9	1144.3	22.47	156.95	34135.1

- 说明：
- 1. 输入长度按中文字符数近似 token 数。
 - 2. TTFT = 请求发出到首个内容 token 到达的时间。
 - 3. TPS 仅统计生成阶段。
 - 4. 聚合吞吐 = 成功生成 token 总数 / cell 总耗时。
 - 5. 使用 streaming 模式测试。